

GreenLight AI

Evaluación Técnica del Sistema

Adrián Pavón Alcón

Antonio Guisado Marin

Proyecto Intermodular · Máster de Inteligencia Artificial y Big Data

Centro FP Superior · Campus Cámara Comercio Sevilla

Mayo 2026

Índice de Contenidos

1. Evaluación del modelo de Machine Learning

- 1.1 Configuración del experimento
- 1.2 Métricas por modelo
- 1.3 Análisis de resultados
- 1.4 Explicabilidad SHAP

2. Evaluación del módulo NLP

- 2.1 Casos de prueba
- 2.2 Análisis de los casos

3. Evaluación del sistema DSS

- 3.1 Comparativa ML vs DSS

4. Rendimiento del sistema completo

5. Limitaciones identificadas y posibles soluciones

1. Evaluación del modelo de Machine Learning

1.1 Configuración del experimento

El modelo se entrenó sobre un dataset sintético de 30.000 registros generado mediante cópula gaussiana. El split fue estratificado: 24.000 muestras para entrenamiento y 6.000 para test. Se usó RobustScaler para el escalado, validación cruzada de 3-fold para estabilidad y scale_pos_weight dinámico (4.8) para gestionar el desbalance de clases.

1.2 Métricas por modelo

Modelo	AUC-ROC	Recall	F1-Score	Precisión
Baseline (LogReg)	0.7051	0.6625	0.3954	0.2818
XGBoost	0.8059	0.6375	0.4889	0.3965
LightGBM	0.8113	0.6548	0.4873	0.3880
CatBoost	0.8154	0.6913	0.4856	0.3743
Random Forest	0.8037	0.5279	0.4933	0.4629
Stacking ★	0.8156	0.7154	0.4860	0.3680

1.3 Análisis de resultados

El Stacking Ensemble es el modelo ganador en las dos métricas prioritarias: AUC (0.8156) y Recall (0.7154). Aunque el AUC es prácticamente idéntico al de CatBoost (0.8154), el Recall del Stacking es 2.4 puntos porcentuales superior. En un contexto médico-deportivo eso no es un detalle menor: significa detectar correctamente a 15 jugadores más de cada 100 lesionados reales.

CatBoost es el mejor modelo individual, y LightGBM el segundo. Random Forest tiene la precisión más alta (0.4629), lo que lo hace el más conservador: predice menos positivos pero acierta más de los que predice. En un sistema de seguridad clínica ese perfil es menos deseable que el de Stacking, que sacrifica algo de precisión a cambio de no perder lesiones.

El umbral óptimo de decisión calculado sobre el conjunto de test es 0.4809. Esto confirma que las probabilidades del Stacking están bien calibradas: no hace falta ajustar el punto de corte artificialmente.

1.4 Explicabilidad SHAP

El análisis SHAP sobre XGBoost revela las tres variables con mayor impacto en las predicciones:

- ACWR:** la variable con mayor impacto absoluto. Valores altos empujan la predicción hacia lesión (SHAP positivo).
- fatigue_score:** segunda en importancia. Fatiga alta se correlaciona directamente con riesgo.
- muscle_soreness:** tercera. Dolor muscular elevado es señal de alerta.

El sueño actúa como factor protector (SHAP negativo): cuando la calidad del sueño es alta, el riesgo baja. Esto valida la hipótesis de que las variables de bienestar subjetivo tienen tanto poder predictivo como las métricas físicas tradicionales coherente con Liu et al. (2026), que sitúan estrés y sueño en el top-3 de predictores de lesión.

2. Evaluación del módulo NLP

2.1 Casos de prueba

Cas o	Posición	Zona · Grado	Decisión	Fuente	Tiempo baja
A	Defensa	Muñeca · grave	● ROJO	REGLA_POSICION_ALTA	6-8 semanas
B	Portero	Muñeca · leve	● ROJO	REGLA_POSICION_ALTA	3-5 días
C	Delantero	Muñeca · leve	● VERDE	REGLA_POSICION_BAJA	3-5 días
D	Delantero	Muñeca · grave	● ROJO	REGLA_POSICION_ALTA	6-8 semanas
E	Defensa	Isquiotibiales · leve	● ROJO	REGLA_POSICION_ALTA	2-3 semanas
F	Delantero	Espalda baja · leve	● VERDE	REGLA_POSICION_BAJA	1-2 semanas
G	Defensa	Zona ambigua · conf. baja	● ROJO	Fallback determinista	6-12 semanas

2.2 Análisis de los casos

Los casos B y C son el ejemplo más claro del valor del sistema experto: la misma lesión (muñeca leve) produce decisiones opuestas según la posición. Para un portero la muñeca es zona ALTA fundamental para parar, atrapar y lanzar.. Para un delantero es zona BAJA, tácticamente irrelevante.

El caso G es el más importante desde el punto de vista de robustez: aunque la zona anatómica no se reconoció con claridad (confianza baja), el sistema activó el fallback determinista y emitió igualmente una decisión conservadora “ROJO” con un tiempo estimado de 6-12 semanas. El sistema nunca se queda sin respuesta.

En los 4 casos de prueba de NLP la extracción fue correcta. En 3 de los 4 lo hizo Mistral; en 1 se activó el parser heurístico por latencia. La coincidencia entre el backend LLM y el heurístico fue del 100%.

3. Evaluación del sistema DSS

3.1 Comparativa ML vs DSS

El siguiente análisis muestra cuándo el DSS corrige la predicción del modelo ML puro:

Caso	ml_prob	ACWR	Decisión ML puro	Decisión DSS	¿Corrige?
B (Portero · muñeca leve)	0.30	1.10	VERDE (baja prob.)	ROJO (REGLA_POSICION_ALTA)	✓ Sí
C (Delantero · muñeca leve)	0.30	1.10	VERDE	VERDE (REGLA_POSICION_BAJA)	No (coincide)
E (Defensa · isquiotibiales)	0.42	1.15	ÁMBAR (prob. intermedia)	ROJO (REGLA_POSICION_ALTA)	✓ Sí
G (zona ambigua)	0.45	1.20	ÁMBAR	ROJO (fallback determinista)	✓ Sí

El sistema experto corrige al modelo ML en 3 de los 4 casos más representativos, siempre en sentido conservador (hacia más precaución). Esto es exactamente el comportamiento esperado en un sistema de seguridad clínica.

4. Rendimiento del sistema completo

Componente	Métrica	Valor
Modelo ML	AUC-ROC	0.8156
Modelo ML	Recall	0.7154
Modelo ML	Umbral óptimo	0.4809
NLP	Extracción correcta	4/4 casos (100%)
NLP	Coincidencia LLM vs Heurístico	100%
DSS	Activación reglas duras en alto riesgo	2/2 casos (100%)
DSS	Correcciones sobre ML puro	3/4 casos (en sentido conservador)
Informe PDF	Generación correcta	100%

5. Limitaciones identificadas y posibles soluciones

- **Datos sintéticos:** el modelo fue entrenado sobre datos generados, no datos GPS reales de un club. La transferencia a producción requiere reentrenamiento con datos reales. Posiblemente se necesitará algún cambio minúsculo en las métricas porque el chaleco sea más moderno, pero no supondría ninguna dificultad a priori.
- **NLP depende de API externa:** si Mistral no está disponible o la confianza es baja, se activa el heurístico, que es menos preciso, pero al menos tenemos una herramienta de respaldo. Por si en algún momento dejará de funcionar la página de mistral.
- **Parser heurístico frágil:** las negaciones, expresiones coloquiales o frases ambiguas pueden dar lugar a extracciones incorrectas. Por ello convendría hacer un parser más potente con más reglas además los diccionarios también deberían ser corpus más grandes.